

概率建模与推断 引言

Michael Gutmann (迈克尔·古特曼)
译者: 郭尚敏 (Shangmin Guo)

School of Informatics, University of Edinburgh

版权声明

本系列幻灯片为作者迈克尔·古特曼在爱丁堡大学 (The University of Edinburgh) 2019 春季学期“概率建模与推断” (Probabilistic Modelling and Reasoning, INFR11134) 课程的授课课件。
译者已经取得原作者的翻译授权。

概率推断

- 概率推断 \equiv 概率推理：
基于能观测的事件计算不能或未曾观测的事件的概率
 - 未观察/不确定事件，例：认知功能障碍 $x = 1$
 - 观察事件 \equiv 证据 \equiv 数据，例：检测结果 $y = 1$
- “先验”：观测数据前，对于不确定事件的概率分布假设，例：
 $Pr(x = 1)$
- “后验”：观测数据后，对于不确定事件的概率分布估计，例：
 $Pr(x = 1|y = 1)$
- 后验可利用贝叶斯法则基于先验和证据计算得出

概率的关键运算法则

① 乘积法则:

$$\begin{aligned}Pr(x = 1, y = 1) &= Pr(y = 1|x = 1)Pr(x = 1) \\ &= Pr(x = 1|y = 1)Pr(y = 1)\end{aligned}$$

② 求和法则:

$$Pr(y = 1) = Pr(x = 1, y = 1) + Pr(x = 0, y = 1)$$

贝叶斯法则可由乘积法则导出:

$$Pr(x = 1|y = 1) = \frac{Pr(x = 1, y = 1)}{Pr(y = 1)} = \frac{Pr(y = 1|x = 1)Pr(x = 1)}{Pr(y = 1)}$$

其中, 分母可根据求和与乘积法则计算:

$$Pr(y = 1) = Pr(y = 1|x = 1)Pr(x = 1) + Pr(y = 1|x = 0)Pr(x = 0)$$

概率的关键运算法则

- 以上法则可以推广到多元随机变量（离散或连续）
- 假设存在变量 x 和 y , 其条件联合概率密度函数 (pdf) 或概率质量函数 (pmf) 为 $p(x, y)$, 以上法则可推广为:

① 乘积规则:

$$\begin{aligned} p(x, y) &= p(x|y)p(y) \\ &= p(y|x)p(x) \end{aligned}$$

② 求和规则:

$$p(y) = \begin{cases} \sum_x p(x, y) & \text{for discrete r.v. (随机变量)} \\ \int p(x, y) dx & \text{for continuous r.v.} \end{cases}$$

概率建模与推断

- 概率建模：

- 首先确定需要建模的事实，以及相关的数量因素
- 假设它们都是随机变量，比如 x 、 y 和 z ，并服从联合 pdf (pmf) $p(x, y, z)$

- 概率推断：

- 假设已知 $y \in \varepsilon$ (测量结果、证据)
- 关于 x 的概率推断是指计算

$$p(x|y \in \varepsilon)$$

或相关量，比如

- $\operatorname{argmax}_x p(x|y \in \varepsilon)$, 最大值
- $\mathbb{E}[g(x)|y \in \varepsilon] = \int g(u)p(u|y \in \varepsilon)du$, 期望值

通过乘积、求和法则求解

假设所有的变量都是离散量，即 $\varepsilon = \{y_o\}$ ，并且已知 $p(\mathbf{x}, y, \mathbf{z})$ ，可通过以下方式求解 $p(\mathbf{x}|y_o)$ ：

- ① 乘积法则： $p(\mathbf{x}|y_o) = \frac{p(\mathbf{x}, y_o)}{p(y_o)}$
- ② 求和法则： $p(\mathbf{x}, y_o) = \sum_{\mathbf{z}} p(\mathbf{x}, y_o, \mathbf{z})$
- ③ 求和法则： $p(y_o) = \sum_{\mathbf{x}} p(\mathbf{x}, y_o) = \sum_{\mathbf{x}, \mathbf{z}} p(\mathbf{x}, y_o, \mathbf{z})$
- ④ 结果：

$$p(\mathbf{x}|y_o) = \frac{\sum_{\mathbf{z}} p(\mathbf{x}, y_o, \mathbf{z})}{\sum_{\mathbf{x}, \mathbf{z}} p(\mathbf{x}, y_o, \mathbf{z})}$$

概率建模与推断的主要问题

$$p(\mathbf{x}|\mathbf{y}_o) = \frac{\sum_{\mathbf{z}} p(\mathbf{x}, \mathbf{y}_o, \mathbf{z})}{\sum_{\mathbf{x}, \mathbf{z}} p(\mathbf{x}, \mathbf{y}_o, \mathbf{z})}$$

假设 $\mathbf{x}, \mathbf{y}, \mathbf{z}$ 均为 $d = 500$ 维向量且向量中每个元素可取 $K = 10$ 个离散值, 那么

- 问题 1: 为了指定 $p(\mathbf{x}, \mathbf{y}, \mathbf{z})$, 我们需要指定 $K^{3d} - 1 = 10^{1500} - 1$ 个非负数, 而这样的计算量明显是不可能的。

主题 1——表示: 为了高效地表示 $p(\mathbf{x}, \mathbf{y}, \mathbf{z})$, 我们可以做哪些合理的弱假设?

概率建模与推断的主要问题

$$p(\mathbf{x}|\mathbf{y}_o) = \frac{\sum_{\mathbf{z}} p(\mathbf{x}, \mathbf{y}_o, \mathbf{z})}{\sum_{\mathbf{x}, \mathbf{z}} p(\mathbf{x}, \mathbf{y}_o, \mathbf{z})}$$

- 问题 2: 上式中求和的操作存在组合爆炸问题, 即分子求和的计算量为 $K^d = 10^{500}$ 、分母求和计算量为 $K^{2d} = 10^{1000}$, 这样的计算量太大、无法完成。

主题 2——精确推断: 我们应该进一步利用 $p(\mathbf{x}, \mathbf{y}, \mathbf{z})$ 所做的那些假设来高效地计算后验概率或者其他想计算的值?

- 问题 3: $p(\mathbf{x}, \mathbf{y}, \mathbf{z})$ 中的非负数应该如何设置才合理?

主题 3——学习: 我们应该如何从数据中学习这些数字?

- 问题 4: 即使在重复利用了所做的假设, 对于有些模型来说, 精确推断还是开销太高。

主题 4——近似推断与学习。